

# 30. 奇异值分解

## 1. 之前的分解

对于之前，我们已经有过各式各样的分解。

诸如  $LU$  分解（任意）、 $QR$  分解（可逆）、对角化（方阵， $n$  个无关特征向量）、相似矩阵（方阵）、正定矩阵（对称）。

但是它们要么 为了更好的分解形式 有着或多或少的要求，要么由于 分解形式不佳 而相对不被重用。

还记得之前的对角化。

如果存在一个方阵  $A$ ，其拥有  $n$  个特征值  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ ，那么或许本矩阵就有可能拥有  $n$  个线性无关的特征向量。


对于这些线性无关的特征向量，利用 施密特正交化 就可以做到让它们两两正交。

从而把  $A = S\Lambda S^{-1}$  写作  $A = Q\Lambda Q^T$  的形式。

而正定矩阵当中，各个特征值又都大于 0，所以  $\Lambda$  变成了一个对角元皆为正数的方阵。

不必说不拥有  $n$  个线性无关特征向量的矩阵了，对于那些非方阵的矩阵，都不能利用这种分解方法。（直至现在，矩阵如果有逆，其与逆都为方阵）

## 2. SVD 的由来



(注:

粉色 代表 正交矩阵  $Q$ ;

橙色 代表 特征值相关的矩阵  $\Lambda$  or  $\Sigma$ ;

绿色 代表 任意形状的矩阵  $A$ )

上方是  $n \times n$ ,  $m \times n$  的矩阵, 下方是任意大小的矩阵  $m \times n$ 。

根据矩阵乘法的性质, 它们可以被分解为右边的三个矩阵相乘的形式。

而上方的三个方阵形式, 也就是代表着:  $A = Q\Lambda Q^T$

这里的  $Q$  是正交矩阵, 它完成了 特征提取 的工作。(只要是特征向量组就可以提取特征值, 不过正交的最好)


那么大胆猜想(才疏学浅还不知动机所在), 是不是任意一个矩阵都可以被分解成 两个正交矩阵 夹另一种 与特征值相关 的矩阵呢。

这或许就是  $SVD$  的出发点。因为如果可以做到, 那么任意一个矩阵都可以被拆解。

### 3. 自基本子空间

#### i. 子空间角度的推导

如果现在要寻找一个对于一般矩阵的分解。




对于一般的矩阵  $A$ , 其四个基本子空间的关系如上图所示。

(只表示垂直关系, 并不意味相交了, 可见两个空间没有交线)

如果我取 行空间中的一个单位向量  $v_1$ , 令其经过某种变换  $A$  之后变为与 列空间的单位向量  $u_1$  平

行 的向量  $Av_1$ ，其中有： $Av_1 = \sigma_1 u_1$ 。

同理，对于另外一个与  $v_1$  垂直的单位向量  $v_2$ ，做同样变换，得到与上面相似的结果。以此类推，得到一组行空间正交基，在经过某种相同变换后，变成 一组列空间正交基。



上图可以表示为：

$$\begin{cases} Av_1 = \sigma_1 u_1 \\ Av_2 = \sigma_2 u_2 \\ \vdots \\ Av_n = \sigma_n u_n \end{cases}$$

转换为矩阵表达：

$$AV = U\Sigma$$

由于此处  $U, V$  都是正交矩阵，有： $UU^T = VV^T = I$ ，所以：

$$A = U\Sigma V^T$$

就把这种对于任意大小矩阵都成立的分解，叫做  $SVD$  分解。

为了分解任意矩阵，要求的方阵就是  $U, V$ 。

对于矩阵  $A$ ，其转置  $A^T = V\Sigma^T U^T$ 。

所以：

$$\begin{cases} A^T A = V \Sigma^T U^T U \Sigma V^T = V (\Sigma^T \Sigma) V^T \\ A A^T = U \Sigma V^T V \Sigma^T U^T = U (\Sigma \Sigma^T) U^T \end{cases}$$

对于中间的矩阵  $\Sigma$ :

$$\begin{bmatrix} \sigma_1^2 & & & & & \\ & \sigma_2^2 & & & & \\ & & \ddots & & & \\ & & & \sigma_r^2 & & \\ & & & & \ddots & \\ & & & & & 0 \end{bmatrix}$$

(需要注意的是, 这个矩阵不一定是一个方阵, 其大小为  $m \times n$ ,  $r$  为原被分解的矩阵  $A$  的秩。

1. 一旦  $r < n$ , 那么就会有 全零列;
2. 如果  $r < m$ , 就会有 全零行。

此矩阵表示的是  $r < m, r < n$  的情形)

(更需要注意的是, 这里有一个约定需要遵守:  $\sigma_1 > \sigma_2 > \cdots > \sigma_r$ )

## ii. 计算原理

通过上面的式子, 我们发现  $\Sigma \Sigma^T$  或者是  $\Sigma^T \Sigma$ , 都是 对角阵。

并且  $U, U^T, V, V^T$  这 4 个方阵都是 正交矩阵。

所以这一组式子, 很容易被理解成  $A A^T, A^T A$  为正定矩阵, 计算  $U$  或者  $V$ , 就是在计算矩阵  $A A^T$  或者  $A^T A$  的正交特征向量组:

$$\begin{cases} A^T A = V \Sigma^T U^T U \Sigma V^T = V (\Sigma^T \Sigma) V^T \\ A A^T = U \Sigma V^T V \Sigma^T U^T = U (\Sigma \Sigma^T) U^T \end{cases}$$

上面一直都在强调 或者 二字, 就是因为最好不要用两种方法分别求  $U, V$ , 因为这两个矩阵是通过等式  $AV = \Sigma V$  关联起来的。